

# 数学课程

## 课前复习

- 课件用法
  - Markdown
  - Jupyter notebook
  - 编辑器：VSCode
    - Python 扩展
    - Markdown 扩展
- 课上教材
  - 李航，统计学习方法。 <https://item.jd.com/12522197.html>
    - 课程前半段，小班同学
    - 机器学习基础理论
    - 传统的算法
    - 面向人群：统计，互联网公司从业人员
    - 传统机器学习算法可以完成所有任务
    - 只不过传统机器学习算法对特征工程要求比较高
  - Goodfellow，深度学习。 <https://item.jd.com/12128543.html>
    - 课程后半段
    - 主要分为：CV（计算机视觉），NLP（自然语言处理）
    - 面向：高新技术企业
    - 所谓的AI（人工智能）有60%指的是深度学习->深度神经网络
  - 阅读、补充材料，有条件有时间可以阅读。
    - Python学习手册， <https://item.jd.com/12452929.html>
      - 面向对Python编程不熟悉的人员
      - 课程主要使用的是Python、
      - 或者看Python文档
      - Python并不是机器学习专属语言
      - 机器学习并不依赖于Python
        - 现在机器学习主要是高性能计算
        - Python大多用于现有库的调用，但是高性能的部分需要C/C++
        - 如果有条件**学习一门高性能的编程语言**，这需要后期补充，面试可能不需要这么深入
    - 算法导论， <https://item.jd.com/11311645.html>
      - 理解图算法、贪心算法、动态规划等一系列算法。

- 如果想短期提升算法能力，可以刷题。
- 面试经常问到。
- 所谓的AI也包括传统算法。
- 信号、图像处理
  - 用于机器学习的特征工程
  - 面试CV方向可能会问到
  - 信号处理
  - 为深度学习打基础。
  - 代码： [第一章-索贝尔滤波.py](#)
  - 代码： [第一章-声音.py](#)
- 最优化理论， <https://item.jd.com/12402926.html>
  - 买任何一本类似的都可以
- 现代几何学

## 思考:什么是机器学习

- 机器学习是从数据中发现规律，并指导生产的学科。
- 机器学习是让机器学习人类知识的过程。
- 机器学习=数据（样本）+模型+优化
  - 数据需要人工采集并标注
  - 模型是对数据真实分布的简化，以及人经验的体现。
  - 优化是求解模型中的参数
- 假设一系列数据点  $(x, y)$ ，求x和y的关系？
  - 首先获取数据，也是获取样本。
  - 假设xy的关系是（建模）： $y=ax+b$
  - 优化过程：使用MSE作为优化函数，进行迭代，称为最小二乘。

## 概率与统计

- 离散和连续类型随机变量
  - 有监督机器学习算法分为：分类算法和回归算法，分类算法就是离散类型的，连续类型的是回归算法。
  - 例子：两枚硬币，分别抛了1000次。A硬币正面出现了800次，B硬币正面出现了200次（获取的样本，有2000个）。此时抛硬币出现了反面，思考抛的是A还是B。算法叫做贝叶斯算法（简化的）
    - 代码： [第二章-抛硬币统计.py](#)
    - 机器学习可以从概率角度理解
    - 机器学习算法并不难。

- 统计概念
  - 期望：
    - $E(x) = \int_{-\infty}^{+\infty} xp(x)dx$ (连续类型)
    - $E(x) = \sum_i x_i p(x_i) = \mu(x)$ (离散类型)
    - 概率应当是研究样本所得
  - 统计量：样本均值
    - $\bar{x} = \sum_i x_i / N$
    - $x_i$ 是样本。
  - 方差
    - $Var(x) = \int_{-\infty}^{+\infty} (x - \mu)^2 p(x)dx$
    - 方差无偏估计  $\frac{\sum_i (x_i - \bar{x})^2}{N-1}$
    - 标准差： $\sigma = \sqrt{Var}$
- 常见分布
  - 高斯分布，正态分布： $N(\mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}$
  - 实例分析：
    - 代码：[第二章-高斯分布随机数分类问题.py](#)
    - 思路s1：统计x0附近，哪一类数据点比较多。
      - 统计过程会遍历样本点，速度很慢。
    - 思路2：（机器学习思路），假设样本符合高斯分布，求解高斯分布分布参数
      - 所谓参数就是样本均值和方差。
      - 通过建模简化了计算过程
      - 机器学习建模均是对数据分布的简化
      - 并不是所有样本均符合假设，但是假设能一定程度完成分类任务。
      - 机器学习是一个近似过程。
- 协方差
  - 代码:第二章-协方差与线性相关系数.py
  - 假设x,y的关系是 $y=ax+b$ （线性关系），意味着xy数据存在冗余。
  - 是否存在线性关系，通过协方差判断。
- 信息熵
  - 衡量系统的混乱程度
  - 仅需要记住数学形式即可
  - e.g.:抛硬币，正0.5反0.5
  - 在知道均值和方差的前提下，高斯分布是最大熵分布。
  - 求高斯分布的熵

## 函数和优化

- 函数的展开

- $f(x_0 + \Delta x) = f(x_0) + f'(x_0)\Delta x + \frac{1}{n!}f^{(n)}(x)\Delta x^n$
- $f(x_0 + \Delta x) \approx f(x_0) + f'(x_0)\Delta x$
- $f(x_0 + \Delta x) - f(x_0) = f'(x_0)\Delta x$
- 如果能让 $f(x)$ 不断减小, 只需要让 $\Delta x = -f'(x)$ , 迭代称为梯度下降法。
- 带入后变为了
  - $f(x_0 + \Delta x) - f(x_0) = -(f'(x_0))^2 \leq 0$
  - 所以 $f(x_0 + \Delta x) \leq f(x_0)$
  - 所以迭代可以逐渐减少。
- $f(x)=x^2+2x$  求函数极小值。 e.g.
  - 代码: [第三章-梯度下降法-1d.py](#)
  - 代码: [第三章-梯度下降法-1d.py](#)

## • 梯度下降法

- 给定函数初始值 $x_0$
- 给定学习率  $\eta$ 
  - 如果学习率过大, 会导致迭代发散。
  - 如果学习率选择过小, 会导致收敛缓慢。
- 计算梯度 (导数)  $g = \nabla f = (\frac{\partial f}{\partial x_i})$
- 执行 $x_t = x_{t-1} - \eta g$
- 直到最大迭代次数, 或结果不再变化。
- eg. 求函数 $f(x_1, x_2)=x_1^2+2x_1x_2+x_2^2$ 的极小值。
- 现有课程优化主要是基于梯度的。

## • 第一个机器学习问题: 假设一系列数据点 $(x, d)$ , 求 $x$ 和 $d$ 的关系?

- 首先假设关系是 $y = ax + b$
- 定义 $y$ 和 $d$ 相似度评价函数,  $L = \sum_i (y_i - d_i)^2 / N$ , 此时称为最小二乘法。
- 目标求解合适的 $a, b$ 使得loss最小
- $g = (\frac{\partial L}{\partial a}, \frac{\partial L}{\partial b})$
- 执行梯度下降法
- 批学习
  - 每次从样本中选择一部分进行训练
- 问题: 如何提升精度?
  - 假设关系为:  $y = ax^2 + bx + c$

## • 名词

- 梯度下降法: 求解函数梯度并进行优化
- 最小二乘法: 损失函数是  $(y-d)^2$ ,  $y$ 模型输出,  $d$ 标签, 是回归问题。
- 批学习: 每次输入多个样本进行训练。
  - 批尺寸越大理论上最终结果精度越高
  - 但是速度越慢。

# 线性代数

- 矩阵和其运算
  - 当成代数工具
  - 简化公式的书写
  - 加减乘除均是代数计算
  - 矩阵求导参考文献：The Matrix Cookbook
  - 概念
    - 对角矩阵：仅在对角线元素有值
    - 方阵：行列相等
    - 逆矩阵： $AB=I$ ，此时AB互为逆矩阵
    - 对称矩阵： $a_{ij} = a_{ji}$ ,  $A^T = A$
- 举例：鸢尾花数据
  - 有150个样本，每个样本有四个属性
  - 所以数据X是一个矩阵，[150, 4]
  - 有三个类，此时标签长度为3
  - 建立模型就是 $Y=XW+b$ ，也是线性模型
- 仿射变换和特征值分解
  - 空间如何进行仿射变换
    - 代码：[第四章-仿射变换.py](#)
  - $Y=XW+b$ 为线性变换，也是仿射变换。
  - 仿射变换可以用于图像的旋转
  - 特征值分解： $A = E\Lambda E^{-1}$ 
    - 对于方阵而言的
    - 实对称矩阵特征值分解： $A = E\Lambda E^T$
    - 分解后E代表空间的旋转，而 $\Lambda$ 代表空间的拉伸
  - SVD分解
    - 对于任意实数矩阵而言的
    - 首先假设矩阵B可以分解为 $B = MQN$ ,  $M^T M = I$
    - 取 $A = B^T B$ ，此时A是对称方阵
    - 对A进行特征值分解： $A = B^T B = N^T Q^T M^T M Q N = N^T = N^T Q^2 N = E\Lambda E^T$
    - 所以 $N = E^T$ ，很容易得M
    - 代码：[第四章-SVD图像压缩.py](#)
  - 了解内容
    - 矩阵QR分解
    - 酉矩阵
    - 广义逆

# API参考

- Numpy：矩阵运算库
  - np.random.normal:产生正态分布随机数
    - 均匀分布通过BoxMuller转换为正态分布。
  - np.random.randint:等概率的产生整形数字
  - np.random.random:产生均匀分布随机数
    - 算法：线性同余发生器
  - np.mean:统计均值
  - np.std:统计标准差
  - 假设x是numpy矩阵
    - x[idx]相当于取以idx为索引的数字。
  - linalg.svd：奇异值分解
  - np.savez()数据保存
  - np.load() 数据加载
    - 参考官方文档
- Matplotlib：绘图库
  - scatter:绘制散点图
  - hist:绘制柱状图
  - plot
- scipy：优化和数据处理库，numpy拓展
- sympy：符号计算库
- LaTeX语法
  - \$\$公式
  - $\beta\gamma_a^b\mathbf{B},\vec{a}$
- Mathematica：计算机代数系统，符号计算用的软件，付费软件。

# 重点

- 概率论
  - 均值、方差等概念
- 函数和优化
  - 梯度迭代算法
- 线性代数
  - 矩阵的运算
- 如果不懂
  - 可以选择性跳过。

- 后面学习完后，再复习。
- 参考书籍《深度学习》前四章。